.UBA fiuba

FACULTAD DE INGENIERÍA

LLMs e IA Generativa

Clase 7 – Agentes y Fine Tuning

Mg. Ing. Ezequiel Guinsburg
ezequiel.guinsburg@gmail.com

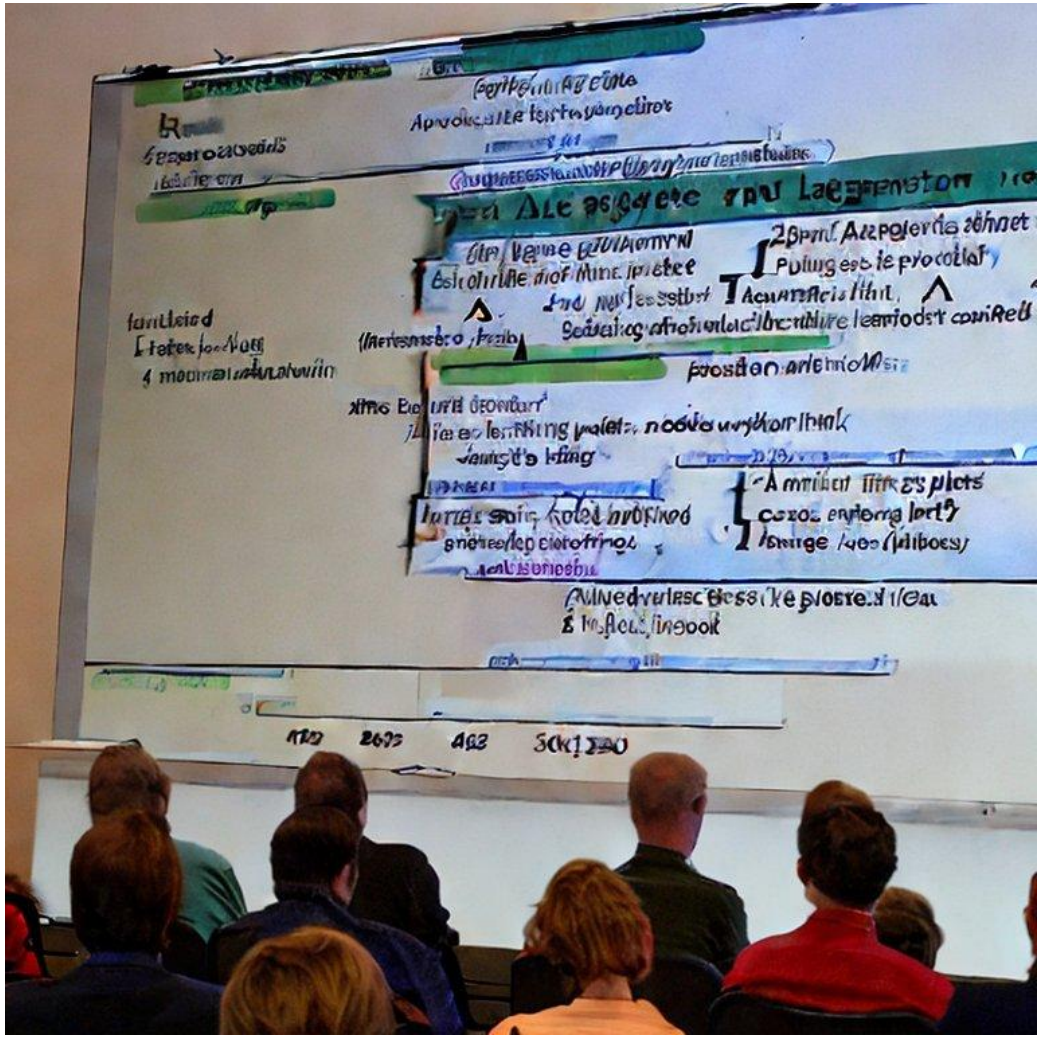

.UBAfiuba
FACULTAD DE INGENIERÍA

Referencias:

[1] Wei et al. “Chain of thought prompting elicits reasoning in large language models.” NeurIPS 2022

[2] Yao et al. “Tree of Thoughts: Dliberate Problem Solving with Large Language Models.” arXiv preprint arXiv:2305.10601 (2023).

[3] Liu et al. “Chain of Hindsight Aligns Language Models with Feedback “ arXiv preprint arXiv:2302.02676 (2023).

[4] Liu et al. “LLM+P: Empowering Large Language Models with Optimal Planning Proficiency” arXiv preprint arXiv:2304.11477 (2023).

[5] Yao et al. “ReAct: Synergizing reasoning and acting in language models.” ICLR 2023.

[6] Ejemplo completo de aplicación de agentes: https://github.com/Significant-Gravitas/AutoGPT

Temas:

- Pendientes de clase 7: Estrategias de segmentación del texto. RAGas.
- Concepto de Agentes y su utilización práctica.
- Fine tuning de grandes modelos de lenguaje.
- Ejercicio práctico.

Segmentación de texto pre-embeddings:

Distintas estrategias:

- División en párrafos u oraciones (depende máximo de Tokens que acepte el modelo de embeddings (ej.: 512 K, 2048 K, etc.).
- Segmentación por Chunking, largo fijo (ejemplo en repo “eguins”).
- Segmentación por contexto semántico (Smart parsing). Referencia.
- Segmentación por ventanas deslizantes por contexto semántico.

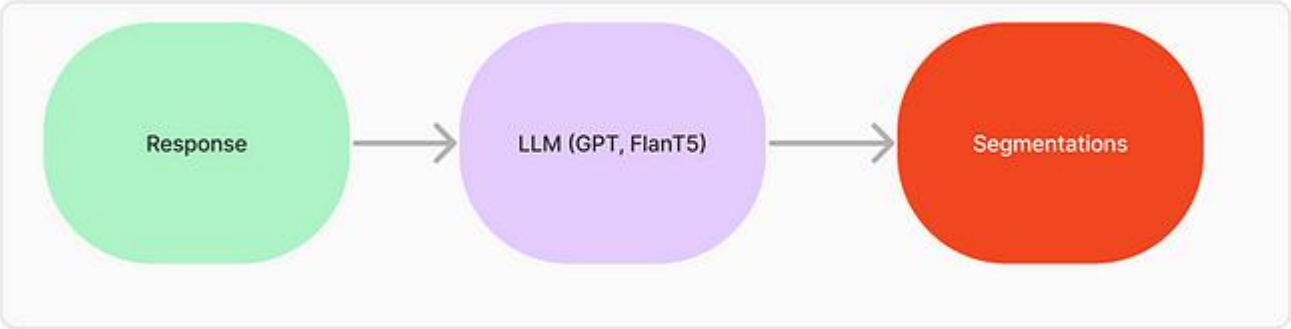

RAGas (**R**etrieval-**A**ugmented **G**eneration **As**sessment)

Framework para evaluar sistemas RAG, utilizando métricas basadas en LLMs y tradicionales.

Repo: https://github.com/explodinggradients/ragas
Ejemplo: https://towardsdatascience.com/evaluating-rag-applications-with-ragas-81d67b0ee31a

	question	contexts	answer	ground_truths	context_precision	context_recall	faithfulness	answer_relevancy
0	What did the president say about Justice Breyer?	['Tonight, I'd like to honor someone who has dedicated his life to serve this country: Jus 'And I did that 4 days ago, when I nominated Circuit Court of Appeals Judge Ketanji Be 'A former top litigator in private practice. A former federal public defender. And from a f	The president thanked Justice Breyer for his service and referred to him as an Army veteran, Constitutional scholar, and retiring Justice of the United States Supreme Court. The president also mentioned that he nominated Circuit Court of Appeals Judge Ketanji Brown Jackson, who will continue Justice Breyer's legacy of excellence.	['The president said that Justice Breyer has dedicated his life to serve the country and thanked him for his service.']	0.50	1.00	1.00	0.85
1	What did the president say about Intel's CEO?	['But that's just the beginning. \n\nIntel's CEO, Pat Gelsinger, who is here tonight, told n 'This is where Intel, the American company that helped build Silicon Valley, is going to b 'For the past 40 years we were told that if we gave tax breaks to those at the very top,	The president did not mention Intel's CEO specifically in the given context.	["The president said that Pat Gelsinger is ready to increase Intel's investment to $100 billion."]	0.00	1.00	0.50	0.83
2	What did the president say about gun violence?	['And I ask Congress to pass proven measures to reduce gun violence. Pass universal b 'As I said last year, especially to our younger transgender Americans, I will always have 'Let's stop seeing each other as enemies, and start seeing each other for who we really	The president called for Congress to pass measures to reduce gun violence, including universal background checks and a ban on assault weapons and high-capacity magazines. He also mentioned the need to repeal the liability shield for gun manufacturers.	['The president asked Congress to pass proven measures to reduce gun violence.']	1.00	1.00	1.00	0.91

Agentes:

- Concepto:
  Sistemas o programas que interactúan con un entorno o realizan tareas específicas de manera autónoma, tomando decisiones basadas en la información que tienen a su disposición.

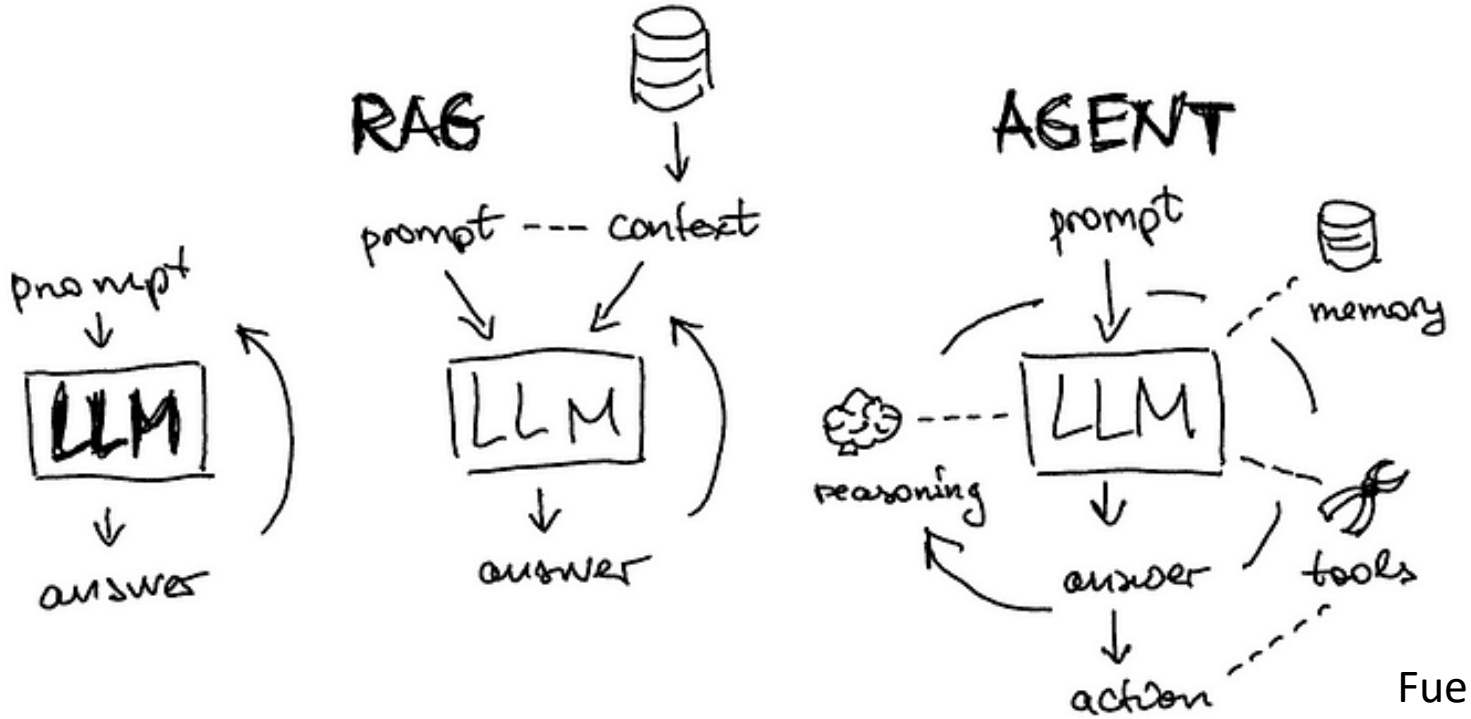

Fuente: Towardsdatascience.com

Agentes:

- Ejemplo: ReAct

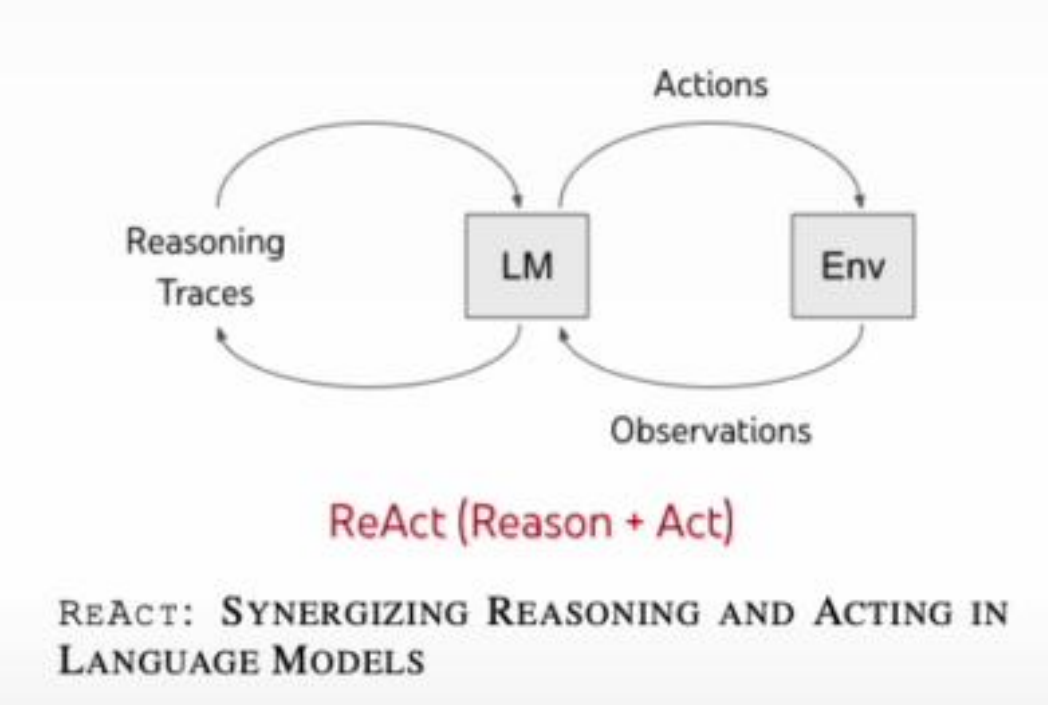

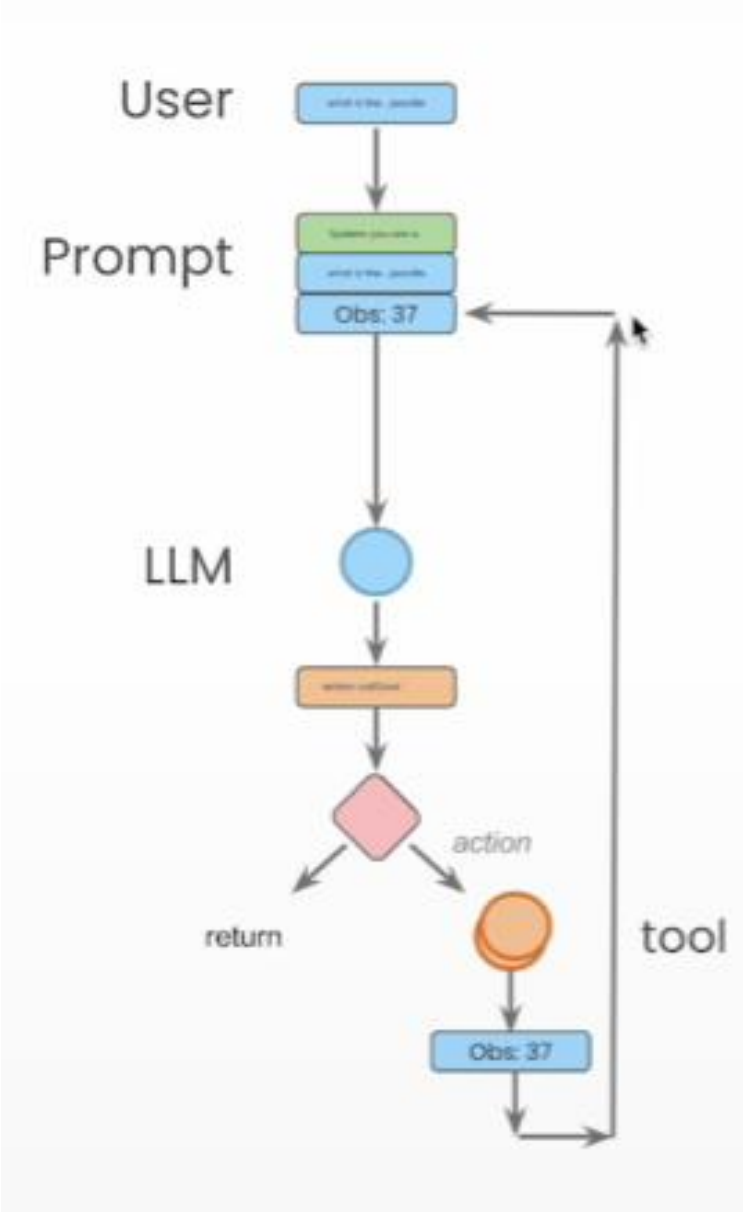

Referencia [5] Yao et al. "ReAct: Synergizing reasoning and acting in language models." ICLR 2023.

Agentes:

- Search Tool

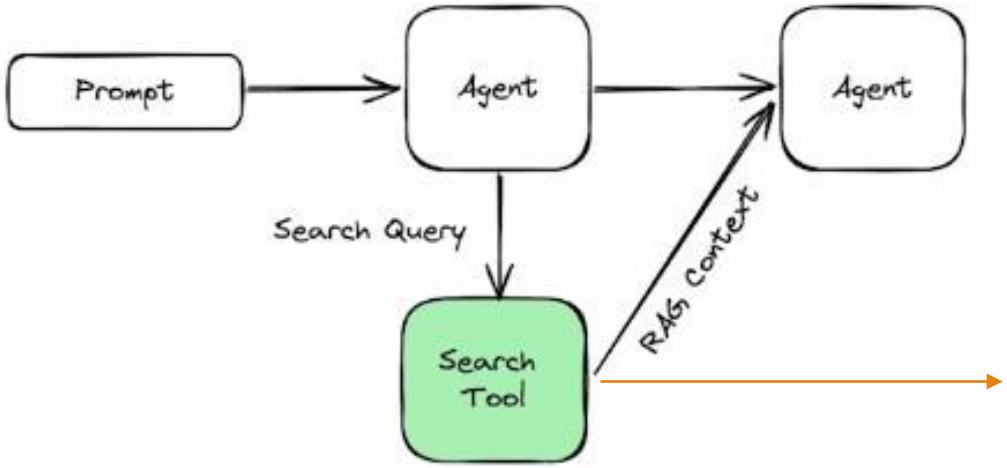

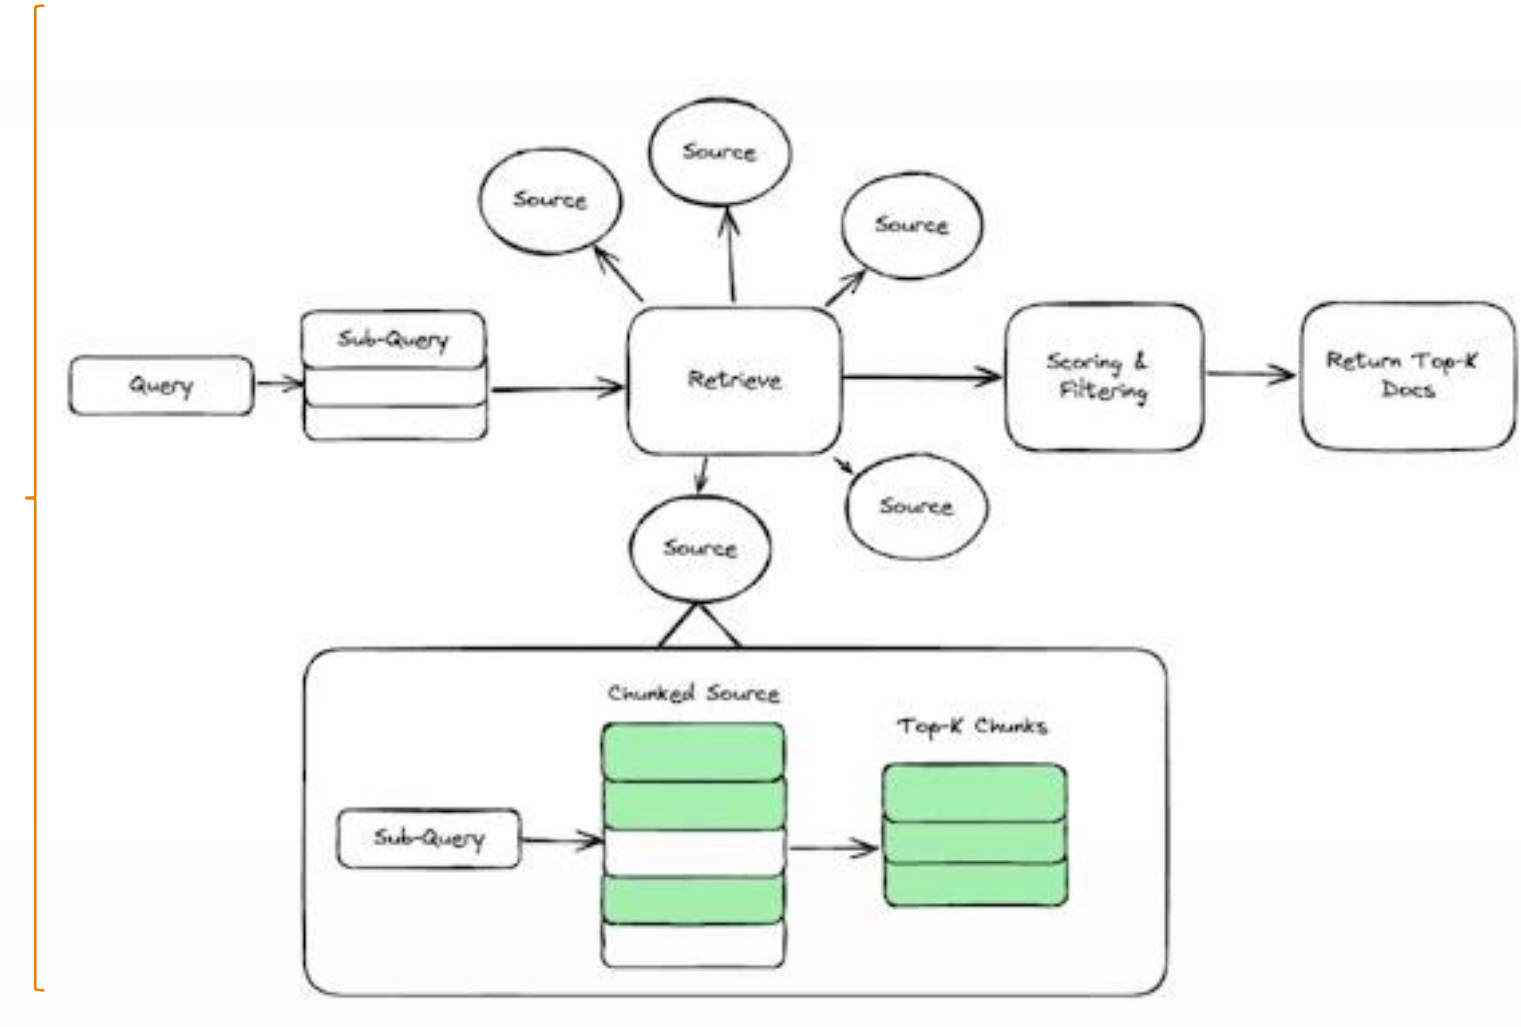

LLM Model Fine Tuning:

- Cuando usarlo?! (prompting Vs. RAG Vs. Fine tuning) -> Clase 8
- Huggingface Transformers / Spacy models fine tuning:
  - On Premise – Open Source
  - En general tamaños chicos de LLMs
  - Privacidad de datos
- OpenAI fine tuning
  - Por medio de API. OpenAI gestiona la infraestructura
  - Se utiliza en modelos grandes
  - El costo se calcula por token
  - El modelo queda guardado por OpenAI

LLM Model Fine Tuning - Huggingface Transformers / Spacy models fine tuning

Ejemplos de uso:

- Clasificación de texto
- Respuestas a preguntas
- Generación de texto
- Traducción
- NER (Named Entity Recognition)
- Resumen (summarization)

LLM Model Fine Tuning: OpenAI fine tuning

(https://platform.openai.com/docs/guides/fine-tuning/)

Disponibles: GPT 4.1, 4o, 4o mini, 3.5 turbo

Casos de uso:

a) Establecer el estilo, tono, formato u otros aspectos cualitativos.
b) Mejorar la confiabilidad al generar una salida deseada.
c) Corregir fallos al seguir indicaciones complejas.
d) Manejar situaciones específicas.
e) Generar una nueva habilidad o tarea que sea difícil de articular en una indicación.

LLM Model Fine Tuning: OpenAI fine tuning

(https://platform.openai.com/docs/guides/fine-tuning/)

Ejemplo de preparación de datos (json):

Validación del dataset: https://cookbook.openai.com/examples/chat_finetuning_data_prep

```
{
  "messages": [
    {"role": "system", "content": "Marv es un chatbot factual que también es sarcástico."},
    {"role": "user", "content": "¿Cuál es la capital de Francia?"},
    {"role": "assistant", "content": "París, como si todo el mundo no lo supiera ya."}
  ]
}
```

Cargar datos ->

```
from openai import OpenAI
client = OpenAI()

client.files.create(
  file=open("mydata.jsonl", "rb"),
  purpose="fine-tune"
)
```

LLM Model Fine Tuning: OpenAI VISION fine tuning

Modelo de dato de entrenamiento --->

```
{
  "messages": [
    { "role": "system", "content": "Eres un asistente que identifica quesos poco comunes."
    { "role": "user", "content": "¿Qué es este queso?" },
    { "role": "user", "content": [
        {
          "type": "image_url",
          "image_url": {
            "url": "https://upload.wikimedia.org/wikipedia/commons/3/36/Danbo_Cheese.jpg"
          }
        }
      ]
    },
    { "role": "assistant", "content": "Danbo" }
  ]
}
```

Restricciones: Máximo 50k ejemplos. Cada ejemplo máximo 10 imágenes. Cada imagen máximo 10 MB
Formatos: JPEG. PNG, WEBP (RGB / RGBA).
Policy: So se puede entrenar con imágenes de personas, caras, chicos ni CAPTCHAs

LLM Model Fine Tuning: OpenAI fine tuning

.UBAfiuba
FACULTAD DE INGENIERÍA

Crear modelo --->

```python
from openai import OpenAI
client = OpenAI()

client.fine_tuning.jobs.create(
  training_file="file-abc123",
  model="gpt-4o-mini-2024-07-18"
)
```

Hiperparámetros--->

- Batch Size (cuanto mayor menor es la varianza)
- Learning Rate Multiplier (Factor de escala del learning rate)
- n_epochs (un epoch es un ciclo entero del dataset)

LLM Model Fine Tuning: precios OpenAI / modelos Llama

.UBAfiuba FACULTAD DE INGENIERÍA

Precios OpenAI ->

gpt-4o-2024-08-06	$10.00 / 1M output tokens	$5.00 / 1M output tokens
	$2.50 / 1M input tokens	$1.25 / 1M input tokens
	$1.25 / 1M cached** input tokens	
	$10.00 / 1M output tokens	$5.00 / 1M output tokens

Model	Pricing	Pricing with Batch API*
gpt-4o-2024-08-06	$3.750 / 1M input tokens	$1.875 / 1M input tokens
	$1.875 / 1M cached** input tokens	
	$15.000 / 1M output tokens	$7.500 / 1M output tokens

Framework de fine tuning para modelos Llama -> https://github.com/pytorch/torchtune

Ejercicio en clase:

- Sobre el trabajo de la clase 6: implementar un sistema de agentes para que responda de manera eficiente dependiendo de qué persona se está preguntando (1 agente por persona).
- **Entregables:** Link a repo público y captura de video de chatbot consultando los CVs de los integrantes del equipo. Por defecto, cuando no se nombra a nadie en la query, utilizar el Agente del alumno.
  Atención: Si se consulta por más de un CV, traer el contexto de cada uno y responder de manera acorde.
  El video debe mostrar todas estas funcionalidades!!

Ejercicio en clase:

- Pasos:
  1. Esquematizar el diagrama flujo que debe tener la aplicación.
  2. Definir el “conditional Edge”, tomador de la decisión. Consejo: utilizar librería **re** y su método **match**.
  3. Implementar cada uno de los pasos y compilar el diagrama de flujo.